

Calibration-Free Transformer 기반 ROS-카메라 융합 좌표 보정 모델

허재혁¹, 김도근¹, 황종락², 권구태¹, 민대영¹, 하윤성¹, 정설영^{1*}

경북대학교 컴퓨터학부¹, 퓨처드라이브²

e-mail : hjh37310@knu.ac.kr, ehrms1009@knu.ac.kr, hjr@futuresdrive.net,
rnjs400703@knu.ac.kr, minty0909@knu.ac.kr, src95891@knu.ac.kr, snowflower@knu.ac.kr

Calibration-Free Transformer-Based ROS-Camera Fusion Model for Coordinate Refinement

JaeHyeok Heo¹, DoGeun Kim¹, Jongrak Hwang²,

Gutae Kwon¹, Daeyoung Min¹, Yunseong Ha¹, Seolyoung Jeong^{1*}

Department of Computer Science and Engineering, Kyungpook National University¹,
FutureDrive²

I. 서론

Abstract

This paper presents a Calibration-Free Transformer-Based ROS-Camera Fusion Model for coordinate refinement in autonomous mobility. Unlike traditional calibration methods, the proposed system automatically performs temporal and spatial alignment between ROS and camera data, then refines trajectories using a Transformer network. The model learns temporal patterns and inter-sensor relationships to produce a unified and refined coordinate sequence, enabling robust estimation even when one sensor fails. Experimental results show that it reduces RMSE by about 30-40% compared to single-sensor models and maintains stable trajectories under noise or dropout. This approach provides a simple and effective way to achieve accurate and reliable multi-sensor fusion without complex calibration.

최근 자율주행 모빌리티의 활용이 빠르게 증가하고 있다. 시스템의 성능은 차량 위치 추정의 정밀도에 달려 있으며, 이를 위해 LiDAR와 Odometry가 주로 사용된다. 그러나 LiDAR는 반사투과 환경이나 특징점이 부족한 공간에서 신뢰도가 저하되고 [1], Odometry는 미끄러짐이나 진동에 의해 오차가 누적된다 [2]. 이를 해결하기 위해 사용되는 기존 LiDAR-카메라 기반 융합 방식은 센서 간 외부 파라미터를 직접 추정해야 하며, 환경이 달라질 때마다 재보정이 필요하다는 한계가 있다 [3]. 최근 Transformer 구조를 활용한 센서 융합 모델들이 제안되고 있으며 [4] [5], 최근에는 Transformer의 attention 메커니즘을 활용해 센서 간 관계를 학습적으로 융합하려는 시도가 등장하고 있으며 [4] [5], 본 논문은 이를 확장하여 데이터의 통계적 대응 관계와 Transformer 학습만으로 센서 좌표를 자동 정렬 및 보정하는 Calibration-Free 융합 구조를 제안한다.

II. 본론

2.1 데이터 수집 및 구성

본 연구에 사용된 데이터는 FutureDrive 기업의 자율주행 테스트 트랙에서 직접 수집하였다. Rosbag을 통해 LiDAR, Odometry, Ackermann 데이터를 동시 기록하였으며, 다중 카메라로 촬영한 영상을 YOLO 모델에 적용해 각 프레임의 bounding box 중심 좌표를 추출하였다. 해당 좌표는 학습 인자로 활용되고, 사람이 검수 및 후보정을 거쳐 Ground Truth로 사용하였다. Rosbag 좌표는 차량 중심의 주행 궤적을, YOLO 좌표는 영상 평면상의 객체 중심을 나타낸다. 두 데이터는 좌표계, 시점, 기록 주기가 달라 정밀한 시간 및 공간 정렬이 필요하다. 그림 1은 데이터 수집 환경을 보여준다.




그림 1. 데이터 수집 환경

2.2 시스템 아키텍처




그림 2. 전체 시스템 아키텍처

그림 2에 나타난 바와 같이, 본 연구에서 제안하는 시스템의 전체 구조는 Temporal Alignment, Spatial Alignment, Normalization, 그리고 Transformer Refinement의 네 단계로 구성된다. 시공간 정렬

단계는 각 센서의 기록 시점과 좌표계를 통계적으로 일치시켜 Transformer가 학습 과정에서 처리해야 할 시간적, 공간적 차이를 최소화한다. Normalization 단계에서는 센서 간 좌표 스케일의 차이를 보정하여 특정 센서 값이 모델 학습에 과도하게 영향을 주는 것을 방지한다. 이후 Transformer가 정렬 및 정규화된 데이터를 입력받아 시간적 패턴과 센서 간 관계를 학습하고 잔여 오차를 보정함으로써, 별도의 calibration 없이도 두 센서 정보를 정밀하게 융합해 일관되고 정확한 좌표를 생성할 수 있다.

2.3 시간 정렬

Rosbag 데이터와 카메라 영상의 시작 시점 및 기록 주기 차이를 해결하기 위해 먼저 시간 오프셋을 추정하여 대략적인 정렬을 수행하였다. 이 과정에서는 차량의 첫 속도 변화 시점과 YOLO의 첫 bounding box 변화 시점이 가장 유사해지는 구간을 탐색하여 시작 시점 차이를 보정하였다. 대략적인 정렬이 완료된 후에는 RMSE 최소화로 시점을 일치하도록 미세 보정하였다. 그림 3은 정렬 전후의 오프셋 변화를 시각화한 결과이다.




그림 3. 시간 오프셋 정렬 전후 비교

2.4 공간 정렬

시간 정렬이 완료된 이후에도 두 데이터는 서로 다른 좌표계를 기반으로 한다. Rosbag은 차량 중심의 2차원 주행 좌표계를, 카메라는 영상 시점의 좌표계를 사용한다. 이러한 좌표계 간 불일치를 보정하기 위해 Umeyama 알고리즘[6]을 이용한 통계적 좌표계 정렬을 수행하였다. 이는 두 점 집합 간의 대응 관계를 이용해 스케일, 회전, 이동을 동시에 추정하여 RMSE를 최소화하며, 센서 간 외부 파라미터를 별도로 측정하거나 보정할 필요가 없다. 즉, 데이터의 통계적 대응 관계만으로 좌표계를 자동 정렬하는 Calibration-Free 방식이다. 그림 4는 시각화를 위해 각 좌표를 개별 정규화한 뒤, 정렬 전후의 ROS-YOLO 궤적을 비교한 결과로, Umeyama 변환 후 두 궤적의 위치가 일치하도록 개선된 모습을 확인할 수 있다.




그림 4. 공간 정렬 전후의 ROS-YOLO 궤적 비교

2.5 데이터 정규화 및 시퀀스 구성

정렬된 데이터는 센서마다 좌표 범위가 다르기 때문에, 학습 시 특정 센서의 값이 지나치게 큰 영향을 주지 않도록 정규화를 수행하였다. 각 주행 구간 별로 평균과 표준편차를 계산하여, 모든 좌표를 평균 0, 표준편차 1로 변환하였다. 이후 각 구간을 일정 길이의 시퀀스로 분할해 ROS, YOLO, Ground Truth 좌표로 구성하였다. 이렇게 만들어진 시퀀스 데이터는 Transformer 모델의 입력으로 사용된다.

2.6 Transformer 기반 좌표 보정 모델

시공간 정렬 후에도 ROS와 YOLO 좌표 간에는 미세한 오차가 남는다. 이를 보정하기 위해 Transformer 기반 좌표 보정 모델을 설계하였다. 모델은 시점 t 에서의 Rosbag 좌표 R_t YOLO 좌표 Y_t 그리고 두 센서 간 차이 $|R_t - Y_t|$ 를 함께 입력받아 시간적 변화와 센서 간 상관관계를 학습한다. Transformer의 self-attention 구조는 이전 프레임의 이동 방향과 속도 패턴을 기반으로, 통계적 정렬로 남은 잔여 오차를 학습 기반으로 보정한다. 결과적으로 Umeyama 기반의 1차 정렬과 Transformer 기반의 2차 보정이 결합되어, 외부

calibration 없이도 두 센서의 시공간 좌표를 정밀하게 일치시킨다. 최종 보정 좌표 $\hat{p}_t$ 는 다음과 같이 계산된다.

$$\hat{p}_t = \alpha_Y Y_t + \alpha_R (R_t + \Delta_t) \quad (1)$$

이 구조를 통해 모델은 각 시점에서 센서의 신뢰도를 추정하고, ROS 기반 주행 정보와 YOLO 기반 관측 정보를 결합하여 안정적이고 정확한 좌표를 산출한다. 즉, 복잡한 외부 calibration 없이도 다중 센서 데이터를 Transformer를 통해 효과적으로 보정 및 융합할 수 있음을 보여준다.

III. 구현

3.1 실험 환경

모델 학습 및 실험은 Python 3.10.8 환경에서 수행되었으며, PyTorch 프레임워크를 기반으로 구현하였다. 학습은 NVIDIA RTX GPU가 탑재된 데스크탑 기반 Anaconda 가상환경에서 진행되었으며, 데이터 정렬과 전처리 과정은 Rosbag 데이터와 OpenCV(cv2) 라이브러리를 활용하여 구현하였다.

전체 데이터셋은 FutureDrive 자율주행 트랙에서 수집된 ROS-카메라 동기화 영상으로 구성되며, 서로 다른 주행 환경에서 촬영된 두 개의 driving session으로 이루어져 있다. 각 세션은 다섯 개의 driving sequence로 세분화되어 있으며, 각 시퀀스는 두 개의 camera viewpoints(정면, 측면 시점)에서 동시에 촬영되었다. 데이터는 5fps로 샘플링된 총 25,138프레임(약 83.8분)으로 구성되어 있으며, session A는 12,423프레임(약 41.4분), session B는 12,715프레임(약 42.4분)으로 이루어진다. 각 주행 시퀀스는 평균 1,000~3,000프레임(3~10분 길이)로 구성되어 있으며, 동일한 주행 구간을 서로 다른 viewpoint에서 기록하였다. 전체 데이터는 학습 60%, 검증 20%, 테스트 20%의 비율로 분할하여 모델 학습에 사용하였다.

3.2 모델 학습 설정

모델은 3개의 인코더 레이어와 4개의 self-attention head로 구성된 Transformer 구조를 사용하였다. 입력은 ROS(2), YOLO(2), 두 좌표 간 차이(2)를 포함한 6차원 벡터로 구성되며, 선형 투영층을 통해 128차원 임베딩 공간으로 변환하였다. feed-forward 층은 256, 활성화 함수는 GELU로 설정하였다. 학습은 AdamW 옵티마이저(학습률 5×10^{-5} , $\beta_1=0.9$, $\beta_2=0.98$)를 사용하였고, 배치 크기는

32로 설정하였다. 모델은 총 100 epoch 동안 학습되었으며, 검증 손실이 더 이상 개선되지 않을 경우 조기 종료하였다. 손실 함수는 좌표 정확도(L_{MSE}), 방향 일관성(L_{dir}), 궤적 부드러움(L_{smooth}), 중심 안정성(L_{center})을 함께 고려하도록 구성하였다.

$$L_{total} = L_{MSE} + \lambda_1 L_{dir} + \lambda_2 L_{smooth} + \lambda_3 L_{center} \quad (2)$$

여기서 각 항목은 다음과 같다.

$$L_{MSE} = \frac{1}{T} \sum_{t=1}^T \|\hat{p}_t - p_t^{GT}\|^2 \quad (3)$$

$$L_{dir} = \frac{1}{(T-1)} \sum_{t=2}^T \|\hat{p}_t - \hat{p}_{t-1} - (p_t^{GT} - p_{t-1}^{GT})\|^2 \quad (4)$$

$$L_{smooth} = \frac{1}{T-2} \sum_{t=3}^T \|\hat{p}_t - 2\hat{p}_{t-1} + \hat{p}_{t-2}\|^2 \quad (5)$$

수식 (3)의 L_{MSE} 은 예측 좌표 와 실제 좌표 간의 평균 제곱 오차이다. 수식(4)의 L_{dir} 은 예측 궤적과 실제 궤적의 방향 일관성을 유지하기 위한 항목이다. 수식(5)의 L_{smooth} 은 연속된 프레임 간 궤적의 부드러움을 유지하기 위한 항목이다. 가중치는 $\lambda_1 = 0.1 (L_{dir})$, $\lambda_2 = 0.05(L_{smooth})$, $\lambda_3 = 0.05 (L_{center})$ 로 설계하였다. 이 손실 설계를 통해 모델은 단순한 좌표 정합 정확도뿐 아니라, 시계열적 연속성과 물리적으로 자연스러운 궤적 형태까지 함께 학습한다.

3.3 성능 평가

제안된 모델의 성능을 검증하기 위해 Rosbag 기반 센서 데이터와 카메라 기반 YOLO 좌표에 각각 다양한 결손 및 잡음 시나리오를 적용하였다. 모든 실험은 동일한 데이터셋과 학습된 모델을 사용하여 수행하였으며, 비교 대상은 Rosbag 기반 단일 입력 모델(Ros-only), YOLO 기반 단일 입력 모델(YOLO-only), 그리고 제안된 하이브리드 모델이다. 각 조건에서의 RMSE 변화를 측정하여 성능 저하율을 비교하였다.

3.3.1 Rosbag 데이터 결손 실험

Rosbag 데이터에 drift, spike, swap, 결측(dropout), freeze, jitter 등의 오류를 주입하여 RMSE 변화를 분석하였다. 표 1은 장애 유형별 결과를 요약한 것이다. ROS-only 모델은 drift, swap 상황에서 오차가 급격히 증가하였지만, 하이브리드 모델은 평균 RMSE 증가율을 10~40% 낮췄다. 특히 swap과 dropout 상황에서는 RMSE가 오히려 감소하여 두 센서가 상호 보완적으로 작용함을 확인할 수 있었다. 이러한 결과는 하이브리드 모델이 입력 신호의 신뢰도에 따라 attention 가중치를 조정하여, 오염된 ROS 입력 대신 YOLO 관측치를 보조 정보로 활용함으로써 안정적인 좌표 추정을 수행함을

보여준다.

	Hybrid ΔRMSE(%)	ROS-only ΔRMSE(%)
Drift	276.30	247.82
Freeze	2.04	0.55
Spike	2.39	3.85
Dropout	-5.27	2.16
Swap	-4.74	35.01
Jitter	2.00	0.52

표 1. Rosbag 데이터 결손 실험 결과

3.3.2 카메라(YOLO) 데이터 결손 실험

YOLO 데이터에 dropout, noise, freeze, swap, jitter 등의 장애를 적용하여 RMSE 변화를 분석하였다. 표 2는 장애 유형별 결과를 요약한 것이다.

	Hybrid ΔRMSE(%)	YOLO-only ΔRMSE(%)
Dropout	829.14	1235.88
Noise	420.56	666.78
Freeze	180.86	291.37
Swap	1538.97	2266.20
Jitter	3.79	4.90

표 2. YOLO 데이터 결손 실험 결과

YOLO-only 모델은 dropout과 swap 상황에서 RMSE가 급격히 증가하였으나, 하이브리드 모델은 ROS 데이터를 보조적으로 활용해 평균 RMSE 증가율을 25~40% 낮췄다. 특히 swap과 noise 상황에서도 비교적 안정적으로 성능을 유지하며, 극단적인 오류 조건에서도 성능 붕괴를 방지하는 효과를 보였다. 이는 YOLO 품질이 저하되는 환경에서도 ROS 기반 주행 정보를 활용해 안정적인 좌표 추정을 수행할 수 있음을 보여준다.

3.3.3 종합 비교

종합적으로, 하이브리드 모델은 ROS 및 YOLO 기반 단일 모델 대비 평균 30~40% 낮은 RMSE 증가율을 유지하였다. 이는 제안된 Transformer 구조가 센서 간 상호보완적 관계를 효과적으로 학습하여, 입력 데이터의 신뢰도가 낮은 상황에서도 안정적인 좌표 추정이 가능하다는 것을 의미한다. 그림 5는 ROS Dropout(40%) 상황에서의 궤적 보정 결과를 나타낸다. ROS-only 모델은 입력 데이터 결손으로 인해 궤적이 불연속적으로 끊기거나 중심부로 수렴하는 형태를 보였다. 반면 제안된 Hybrid 모델은 YOLO 기반 좌표 정보를 함께 활용하여 누락된

구간을 자연스럽게 보간하였으며, Ground Truth에 가장 근접한 형태로 궤적을 복원하였다. 특히 전체적인 이동 방향과 곡률이 안정적으로 유지되어, 제안된 하이브리드 모델이 센서 결손 환경에서도 시간적 연속성과 공간적 일관성을 안정적으로 유지함을 보여준다.




그림 5. ROS Dropout(40%) 상황에서 좌표 보정 결과

IV. 결론 및 향후 연구 방향

본 연구에서는 통계적 시공간 정렬과 Transformer 학습 보정을 결합한 Calibration-Free ROS-Camera 융합 시스템을 제안하였다. 시공간 정렬은 센서 간 좌표 불일치를 줄이고, Transformer는 잔여 오차를 학습 기반으로 보정하여 두 센서의 정보를 융합한 정확한 좌표를 생성한다. 실험 결과, 제안 모델은 ROS-only 및 YOLO-only 모델 대비 RMSE가 평균 30-40% 낮았으며, 결손 및 잡음 환경에서도 안정적인 성능을 보였다. 이는 복잡한 calibration 과정 없이도 ROS와 카메라 데이터를 통합해 정밀한 좌표 추정을 달성할 수 있음을 검증하였다. 향후에는 CNN 기반 환경 신뢰도 추정 모듈을 추가하여 다양한 주행 환경에서도 자동으로 센서 신뢰도를 조정하고, 보다 일반화된 자동 정렬 기반 융합 구조로 확장할 예정이다.

참고문헌

[1] C. Yang, Z. Chai, X. Yang, H. Zhuang, and M.

Yang, "Recognition of Degradation Scenarios for LiDAR SLAM Applications," *Proc. of the IEEE International Conference on Robotics and Biomimetics (ROBIO)*, pp. 1726-1731, Jinghong, China, Dec. 2022.

- [2] R. Aldera, D. D. Martini, M. Gadd, and P. Newman, "What Could Go Wrong? Introspective Radar Odometry in Challenging Environments," *Proc. of the IEEE Intelligent Transportation Systems Conference (ITSC)*, pp. 2835-2842, Auckland, New Zealand, Oct. 2019.
- [3] X. Lv, B. Wang, Z. Dou, D. Ye, and S. Wang, "LCCNet: LiDAR and Camera Self-Calibration Using Cost Volume Network," *Proc. of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR) Workshops*, pp. 2894-2901, 2021.
- [4] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser, and I. Polosukhin, "Attention Is All You Need," *Proc. of the 31st International Conference on Neural Information Processing Systems (NeurIPS)*, Long Beach, USA, 2017.
- [5] K. Chitta, A. Prakash, B. Jaeger, Z. Yu, K. Renz, and A. Geiger, "TransFuser: Imitation with Transformer-Based Sensor Fusion for Autonomous Driving," *IEEE Transactions on Pattern Analysis and Machine Intelligence (TPAMI)*, vol. 45, no. 11, pp. 12878-12895, Nov. 2023.
- [6] S. Umeyama, "Least-Squares Estimation of Transformation Parameters Between Two Point Patterns," *IEEE Transactions on Pattern Analysis and Machine Intelligence (PAMI)*, vol. 13, no. 4, pp. 376-380, Apr. 1991.

감사의 글

본 연구는 과학기술정보통신부 및 정보통신기획평가원의 SW 중심대학사업의 연구결과로 수행되었음(2021-0-01082)

본 연구는 FutureDrive와의 산학협력 프로젝트의 일환으로 수행되었으며, 과학기술정보통신부의 재원으로 연구개발특구진흥재단의 지원을 받아 수행된 연구임(RS-2025-02634821).

본 과제(결과물)는 교육부와 한국연구재단의 재원으로 지원을 받아 수행된 첨단분야 혁신융합대학사업의 연구결과입니다.