

V2X 협력 인지 환경에서 동적 ROI 필터링과 CNN 기반 위험 히트맵을 활용한 효율적 장애물 선별

Efficient Obstacle Filtering Using Dynamic ROI and CNN-Based Risk Heatmap in V2X Cooperative Perception

허재혁¹, 황종락², 김도근¹, 권구태¹, 민대영¹, 하윤성¹, 김동균¹
Jae-Hyeok Heo, Jong-Rak Hwang, Do-Geun Kim, Gu-Tae Kwon,
Dae-Young Min, Yun-Seoung Ha and Dong-Kyun Kim

¹경북대학교 컴퓨터학부
E-mail: hjh37310@knu.ac.kr
²퓨처드라이브
E-mail: hjr@futuredrive.net

요약

V2X(Vehicle-to-Everything) 협력 인지 환경에서는 자차 센서 범위를 넘어선 장애물 정보가 대량으로 수신되어, 모든 장애물에 대해 정밀 충돌 판정을 수행하면 실시간 처리가 어렵다. 본 논문은 이를 해결하기 위해 단계적 정밀화(Coarse-to-Fine) 파이프라인을 제안한다. 먼저 자차 속도에 연동하여 동적으로 관심 영역(Region of Interest, ROI)을 설정하고, ROI 내 장애물을 10×10 그리드의 5 채널 텐서로 인코딩한 뒤 경량 합성곱 신경망(Convolutional Neural Network, CNN)으로 위험 가능 영역 히트맵을 출력한다. nuScenes 데이터셋을 활용한 실험 결과, 제안 방법은 장애물 처리량을 78.0% 감소시키면서 위험 장애물 누락률 2.7%를 달성하여, 처리 효율과 안전성의 균형을 확보하였다.

키워드: V2X, 협력 인지, 충돌 위험 감지, 동적 ROI, CNN 히트맵

1. 개요

V2X 협력 인지는 다중 차량 간 센서 정보 교환을 통해 자차 센서만으로는 감지할 수 없는 사각지대의 장애물 정보를 확보할 수 있다 [1]. 그러나 수신 장애물 수가 급증하면, 각 장애물에 대해 TTC·DCPA 등의 정밀 충돌 판정을 전수 수행하는 것은 실시간 처리에 큰 부담이 된다.

고정 거리 임계값 기반 필터링은 저속에서는 불필요한 장애물을 과도하게 포함하고 고속에서는 원거리 위험 장애물을 누락하는 상충 관계가 존재한다. 본 논문은 자차 속도에 연동한 동적 원형 ROI로 공간적 사전 필터링을 수행하고, 그리드 인코딩과 경량 CNN으로 위험 가능 영역만을 선별하는 단계적 정밀화(Coarse-to-Fine) 파이프라인을 제안한다.

2.1 동적 ROI 필터링

선행연구에서 차량 운동학에 기반한 적응형 ROI가 정적 ROI의 오탐 및 누락 문제를 완화함이 확인되었다 [2]. 본 논문에서는 자차의 현재 속도에 비례하여 원형 ROI의 반지름을 동적으로 설정하며, ROI 외부 장애물은 즉시 제거된다. 고속일수록 전방 영역이 확장되고 저속일수록 근거리가 집중되어, 고정 ROI의 속도별 상충 관계를 단일 파라미터로 해소한다. 도형 실험(원형, 정사각형, 부채꼴, 사다리꼴)에서 원형이 위험 장애물 누락을 최소화하였으며, 면적(200~3,000 m²)·속도 계수(0~20) 격자 탐색(315가지 조합)에서 면적 1,600 m²·k=20이 균형점으로 선정되었다. 동적 ROI는 고정 ROI 대비 중속 구간에서 누락률을 49% 감소시켰다.

2.2 그리드 인코딩 및 CNN 위험 히트맵

ROI 내 장애물을 10×10 그리드(셀 크기 약 11 m)에 배치하고, 각 셀별로 5개 채널(차량 점유, 보행자 점유, 장애물 최대 속도, 자차 속도, 접근률)을 갖는 텐서로 인코딩한다. 기존 연구에서는 자차 주변 공간의 충돌 위험도를 정량화하는 방법론이 제안된 바 있으나 [3], 본 논문에서는 인코딩된 텐서를 경량 CNN에 입력하여 위험 가능 영역을 히트맵 형태로 출력하는 방식을 취한다. 출력된 히트맵에서 임계값이 0.1 이상인 셀에 포함된 장애물만을 선별하여, 후속 정밀 판정 단계로 전달함으로써 연산 효율을 높인다.

그리드 해상도 실험(5×5~18×18)에서 5×5·7×7은 OMCR 30% 이상, 14×14 이상은 AP 0.4 미만으로 저하되어 10×10이 균형점으로 선정되었다. 채널 구성 실험(7가지 조합)에서 5 채널 구성이 AP 0.630으로 최적이었으며, 자차 속도·접근률 채널이 모두 필요하고 점유 채널의 분리가 유효함을 확인하였다. 과거 프레임 스택킹 실험

2. 단계적 정밀화 장애물 필터링



그림 1. 제안 파이프라인 구조.

Fig. 1 Proposed pipeline architecture

감사의 글 : 본 연구는 과학기술정보통신부 및 정보통신기획평가원의 SW 중심대학사업의 연구결과로 수행되었음 (2021-0-01082)

(1~3 프레임)에서는 프레임 수 증가에 따라 OMCR 이 6.5%에서 25.8%로 증가하여 단일 프레임 입력을 채택하였다. 아키텍처 구성 실험(채널 폭 $8 \cdot 16 \cdot 32 \times BN$ 유무)에서는 채널 폭이 좁을수록 AP-OMCR 이 우수하나 장애물 감소율이 저하되어, 두 지표를 함께 고려한 16 채널 구조를 채택하였으며, 배치 정규화는 모든 조합에서 성능을 저하시켜 제외하였다. 그림 2는 실제 장면에서의 동적 ROI 및 CNN 위험 히트맵 출력 예시를 보여준다.




그림 2. 단일 프레임에서의 동적 ROI 및 CNN 위험 히트맵 출력 예시 (ego 속도: 8.0 m/s).

Fig. 2 Example output of dynamic ROI and CNN-based risk heatmap for a single frame

3. 실험 및 결과

3.1 실험 환경

nuScenes v1.0-trainval 데이터셋 [4](850 scenes, 34,149 프레임, 887,733 장애물)을 사용하였으며, scene 단위 90/10 비율로 학습/검증을 분할하였다. GT는 TTC 기반 [5] 정답 라벨을 사용하여 TTC 2 초 미만 장애물을 위험으로 정의하였다. 모든 실험은 AMD Ryzen 5 7500F CPU, NVIDIA GeForce RTX 3080 (CUDA 12.4), Python 3.10.20, PyTorch 2.5.1 환경에서 수행하였다.

3.2 실험 결과

표 1. 방법별 성능 비교.

Table 1. Performance comparison of filtering methods.

Method	RR(%)	OMCR(%)	Latency(ms)
No Filter	0.0	0.0	~0
Rule-based 1	36.2	10.0	0.022
Rule-based 2	53.2	0.6	0.279
Proposed	78.0	2.7	0.442

제안 방법의 성능을 검증하기 위해 4 가지 방법을 비교하였다(표 1). 평가 지표는 감소율(RR)과 위험 장애물 전체 누락률(OMCR)을 사용하며, 이는 각각 연산 효율과 안전성을 반영한다. 규칙 기반(Rule-based) 1은 장애물까

지의 거리가 51 m 미만이고 접근속도가 양수인 경우만 선별하는 단순한 방법이다. 규칙 기반 2는 1 단계 동적 ROI 필터링 후, 균등 가중치와 가우시안 평활화를 적용하여 위험 히트맵을 생성하는 비학습 방법이다.

규칙 기반 1은 감소율 36.2%에 그치며 전체 누락률 10.0%로 실용성이 부족하다. 규칙 기반 2는 전체 누락률 0.6%로 안전하지만 감소율이 53.2%에 머물러 연산 감소 효과가 제한적이다. 제안 방법은 감소율 78.0%로 장애물을 대폭 감소시키면서 전체 누락률 2.7%를 달성하여, 두 지표의 균형을 확보하였다.

제안 파이프라인의 지연 시간은 0.442 ms 로 규칙 기반 2(0.279 ms)보다 높으나, 후속 3 단계의 장애물당 정밀 연산 비용이 0.043 ms 를 초과하는 시점부터 전체 처리 시간이 역전되어 제안 방법이 유리하다. 수신 장애물 수가 증가하는 V2X 협력 인지 환경일수록 필터링 효과가 커지므로, 제안 파이프라인은 대규모 협력 인지 시나리오에 적합하다.

4. 결론

본 논문은 V2X 협력 인지 환경에서 장애물 급증 문제를 해결하기 위한 단계적 정밀화 필터링 파이프라인을 제안하였다. 동적 ROI와 CNN 기반 위험 히트맵의 결합을 통해 장애물 처리량을 78.0% 감소시키면서 위험 장애물 누락률 2.7%를 달성하였다. 향후 CNN 의 학습 기준을 TTCP/DCPA/제동 TTC 기반으로 재정의하여 누락률을 추가 개선하고, 다중 프레임 시간 정보를 활용한 확장을 계획하고 있다.

참 고 문 헌

- [1] X. Kuang, H. Zhu, B. Yu, and B. Li, "Fast Clustering for Cooperative Perception Based on LiDAR Adaptive Dynamic Grid Encoding," Cognitive Computation, vol. 16, pp. 546-565, 2024.
- [2] S. Han, M. Choi, B. Jang, K. H. Choi, and K.-S. Kim, "Adaptive ROI for Collision Warning Mitigation Based on Road Geometry and Kinematics," IEEE Sensors Journal, vol. 25, no. 3, pp. 5499-5509, 2024.
- [3] R. Nahata, D. Omeiza, R. Howard, and L. Kunze, "Assessing and Explaining Collision Risk in Dynamic Environments for Autonomous Driving Safety," Proc. IEEE Intelligent Transportation Systems Conf. (ITSC), pp. 223-230, 2021.
- [4] H. Caesar, V. Bankiti, A. H. Lang, S. Vora, V. E. Liong, Q. Xu, A. Krishnan, Y. Pan, G. Baldan, and O. Beijbom, "nuScenes: A Multimodal Dataset for Autonomous Driving," Proc. IEEE/CVF CVPR, pp. 11621-11631, 2020.
- [5] C. Qu, W.-Y. Qi, and P. Wu, "A High Precision and Efficient Time-to-Collision Algorithm for Collision Warning Based V2X Applications," Proc. 2nd Int. Conf. Robotics and Automation Sciences (ICRAS), pp. 62-69, 2018.